

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



وزارت علوم، تحقیقات و فناوری

دانشگاه بناب

دانشکده علوم پایه

گروه ریاضی و علوم کامپیوتر

پروژه کارشناسی رشته علوم کامپیوتر، گرایش عمومی با عنوان

یادگیری فیزیک آگاه با قیود سخت برای مدیریت انرژی ریز شبکه متصل به شبکه

استادان راهنما

دکتر بابک آذرنوید

دکتر زهرا مختارنژاد

نگارش

محمد امیر بابازاد

شماره دانشجویی: ۱۴۰۲۱۳۵۱۰۴

شهریور ۱۴۰۵

سال تحصیلی ۱۴۰۵ تا ۱۴۰۶

تقدیم

تقدیم به پدر و مادرم.

سپاسگزاری

از استادان راهنما، دکتر بابک آذرنوید و دکتر زهرا مختارنژاد، که در طول انجام تحقیق راهنمایی فرمودند، قدردانی می‌شود. از گروه ریاضی و علوم کامپیوتر دانشگاه بناب نیز سپاسگزاری می‌گردد. مسئولیت کاستی‌های احتمالی بر عهده نگارنده است.

چکیده

مدیریت انرژی ریزشبه متصل به شبکه باید همزمان هزینه بهره‌برداری و قیود فیزیکی باتری را در نظر بگیرد. یک شبکه عصبی که توان شبکه، شارژ، دشارژ و وضعیت شارژ را به‌طور مستقل پیش‌بینی می‌کند، ممکن است با وجود خطای تقریب کم، فرمانی ناممکن مانند شارژ و دشارژ همزمان یا وضعیت شارژ خارج از بازه مجاز تولید کند. در این پژوهش، یک شبکه فیزیک‌تعبیه‌شده پیشنهاد شده است که فقط فرمان علامت‌دار باتری را می‌آموزد. یک لایه تحلیلی بدون پارامتر، توان‌های شارژ و دشارژ، وضعیت شارژ گام بعد و توان شبکه را چنان می‌سازد که توازن توان، حدود وضعیت شارژ، سقف توان باتری، نامنفی بودن توان‌ها و عدم شارژ/دشارژ همزمان برقرار باشند.

مطالعه موردی شامل ۳۲۸۹ رکورد ساعتی در بازه پردازش‌شده ساعت ۱۷ روز ۱۱ ژانویه تا ساعت ۱۷ روز ۲۷ مه ۲۰۱۶ است و از داده عمومی ترکیبی ساخته شده است: بار از مجموعه داده عمومی مصرف وسایل و روشنایی، و تابش از NASA POWER آمده است؛ مدل PV، بار زمینه و تعرفه، فرض‌های مستند مهندسی‌اند. یک برنامه‌ریزی پویای مقید، برنامه مرجع را تولید کرد. شبکه داده‌محور آزاد و شبکه فیزیک‌تعبیه‌شده با افراز زمانی ۲۰/۲۰/۶۰ و پنج بذر آموزش و روی آزمون بازگشتی مقایسه شدند.

مدل فیزیک‌تعبیه‌شده باقیمانده توازن و همه نرخ‌های نقض قید تعریف‌شده را در محاسبه شناور به صفر رساند. مدل داده‌محور خام، با وجود MSE کمتر، حدود ۷٫۱٪ نقض وضعیت شارژ و ۴۰٫۹٪ شارژ/دشارژ همزمان تولید کرد. هزینه مدل فیزیک‌تعبیه‌شده 0.242 ± 17.186 بود: ۲۱٫۴٪ کمتر از حالت بدون باتری و ۱٫۶٪ بیشتر از مرجع برنامه‌ریزی پویا. هزینه آن با مدل داده‌محور ترمیم‌شده (0.492 ± 17.529) قابل مقایسه و به‌طور میانگین اندکی کمتر بود، اما این تفاوت در پنج بذر معنادار نیست. صفر بودن نقض‌ها خاصیت طراحی است، نه کشف آماری. نتیجه فقط به این مطالعه موردی عمومی/ترکیبی محدود است و به بهره‌برداری صنعتی یا داده میدانی تعمیم داده نمی‌شود.

واژه‌های کلیدی: یادگیری فیزیک‌آگاه، قید سخت، ریزشبه متصل به شبکه، مدیریت انرژی، باتری

فهرست علائم و اختصارات

نمادها به ترتیبی آمده‌اند که در متن ظاهر می‌شوند. توان‌ها بر حسب کیلووات، انرژی باتری بر حسب کیلووات‌ساعت و گام زمان برابر یک ساعت است.

الف) کمیت‌های سامانه

نماد	معنی
t	شماره گام زمانی
$P_L(t)$	توان مصرفی بار
$P_{PV}(t)$	توان تولیدی فتوولتائیک
$P_G(t)$	توان خالص شبکه؛ مثبت برای خرید و منفی برای فروش
$P_c(t)$	توان شارژ باتری، نامنفی
$P_d(t)$	توان دشارژ باتری، نامنفی
$u(t)$	فرمان علامت‌دار باتری؛ مثبت شارژ و منفی دشارژ
$u_{safe}(t)$	فرمان مدل داده‌محور پس از گیره و نگاشت ایمنی
P_{max}	سقف توان شارژ یا دشارژ باتری
$s(t)$	وضعیت شارژ باتری، عددی بین صفر و یک
s_{min}, s_{max}	کف و سقف مجاز وضعیت شارژ
E_{max}	ظرفیت انرژی باتری
η_c, η_d	بازده شارژ و دشارژ
Δt	طول گام زمان
$c_b(t), c_s(t)$	قیمت خرید و فروش برق
κ	ضریب هزینه عبور انرژی از باتری
$[z]_+$	بخش مثبت z ، برابر با $\max(0, z)$

(ب) کمیت‌های یادگیری و ارزیابی

معنی	نماد
بردار ورودی شبکه در ساعت t	$\mathbf{x}(t)$
خروجی مرجع برنامه‌ریزی پویا	$\mathbf{y}^*(t)$
خروجی آزاد شبکه پیش از نگاشت فیزیکی	$\mathbf{z}(t)$
باقیمانده توازن توان	$r_G(t)$
هزینه آینده در برنامه‌ریزی پویا	$V_t(s)$
مجموعه فرمان‌های مجاز در SOC فعلی	$\mathcal{U}(s)$
خطای آموزش فرمان باتری	$\mathcal{L}_u$
MSE میانگین گرفته‌شده روی چهار مؤلفه خروجی	MSE_{comp}

(پ) اختصارات

معنی	اختصار
شبکه عصبی فیزیک‌آگاه	PINN
وضعیت شارژ باتری	SOC
برنامه‌ریزی پویا	DP
میانگین مربع خطا	MSE
فتوولتائیک	PV

فهرست مطالب

آ	تقدیم
ب	سپاسگزاری
پ	چکیده
ت	فهرست علائم و اختصارات
ج	فهرست مطالب
ح	فهرست تصاویر
خ	فهرست جداول
۱	۱ کلیات تحقیق
۱	۱-۱ مقدمه
۱	۱-۲ مسئله تحقیق
۲	۱-۳ هدف و پرسش‌های تحقیق
۲	۱-۴ سهم کار
۲	۱-۵ داده و قلمرو
۳	۱-۶ ساختار گزارش
۴	۲ مبانی نظری و پیشینه پژوهش
۴	۲-۱ مدل ریزشکه متصل به شبکه
۴	۲-۲ توازن توان و دینامیک باتری
۵	۲-۳ هزینه بهره‌برداری
۵	۲-۴ یادگیری فیزیک آگاه و قید سخت
۵	۲-۵ جایگاه کار در پیشینه
۵	۲-۵-۱ مدیریت انرژی مبتنی بر بهینه‌سازی
۶	۲-۵-۲ مدیریت انرژی مبتنی بر یادگیری
۶	۲-۵-۳ اعمال قید در کنترل‌کننده‌های یادگرفته‌شده

۶	۲-۵-۴ یادگیری فیزیک آگاه در سامانه های انرژی
۷	۲-۶ مرجع برنامه ریزی پویا
۷	۲-۷ جمع بندی فصل
۸	۳ روش شناسی
۸	۳-۱ جریان کلی آزمایش
۸	۳-۲ بردار ورودی و مرجع آموزشی
۹	۳-۳ شبکه داده محور آزاد
۹	۳-۴ شبکه فیزیک تعبیه شده
۱۰	۳-۵ تنظیم آموزش و افراز داده
۱۰	۳-۶ شاخص های ارزیابی
۱۱	۴ پیاده سازی و تحلیل نتایج
۱۱	۴-۱ داده عمومی و قابلیت بازتولید
۱۲	۴-۲ تنظیمات اجرا
۱۲	۴-۳ نتایج دقت و قیود
۱۴	۴-۴ هزینه اجرایی
۱۵	۴-۵ تفسیر و محدودیت ها
۱۶	۵ نتیجه گیری و پیشنهادها
۱۷	آ مشخصات بازتولید پذیری
۱۹	ب شبه کد لایه خروجی تحلیلی
۲۰	منابع

فهرست تصاویر

۳-۱	جریان مطالعه موردی و مقایسه کنترل کننده ها	۸
۴-۱	بار و PV مطالعه موردی و SOC کنترل کننده ها در نخستین روز آزمون	۱۳
۴-۲	قدر مطلق باقیمانده توازن توان در هفته نخست آزمون	۱۳
۴-۳	میانگین هزینه روزانه برنامه های قابل اجرا روی افق آزمون	۱۴

فهرست جداول

۶	مقایسه رویکردهای تولید برنامه انرژی	۲-۱
۱۱	منشأ مؤلفه‌های مطالعه موردی	۴-۱
۱۲	میانگین و انحراف معیار پنج بذر روی افق آزمون	۴-۲
۱۲	شاخص‌های امکان‌پذیری روی مجموعه آزمون	۴-۳
۱۴	هزینه اجرایی افق آزمون؛ واحد پولی مفروض	۴-۴
۱۷	پارامترهای کامل شبیه‌سازی و آموزش	آ-۱

فصل ۱

کلیات تحقیق

۱-۱ مقدمه

گسترش تولید پراکنده و ذخیره‌سازی در سمت مصرف، واحدهایی با تصمیم‌گیری انرژی مستقل را در شبکه توزیع رایج کرده است [1]. ریزشبکه متصل به شبکه، مجموعه‌ای از بار، تولید محلی، ذخیره‌ساز و نقطه تبادل با شبکه بالادست است. در هر ساعت باید تصمیم گرفته شود که باتری شارژ یا دشارژ شود و کمبود یا مازاد توان چگونه با شبکه مبادله گردد. این تصمیم تنها اقتصادی نیست؛ توازن توان، ظرفیت باتری، بازده تبدیل و حدود وضعیت شارژ نیز باید رعایت شوند. در پژوهش‌های مدیریت انرژی، همین قیود بهره‌برداری در کنار هزینه خرید، فروش و استهلاک باتری صورت‌بندی می‌شوند [2].

شبکه عصبی می‌تواند نگاهی سریع میان وضعیت ریزشبکه و فرمان بهره‌برداری بیاموزد، اما خروجی آزاد یک شبکه لزوماً قابل اجرا نیست. برای مثال، ممکن است توان شارژ منفی، شارژ و دشارژ هم‌زمان، یا وضعیت شارژ خارج از بازه مجاز پیشنهاد شود. جریمه نرم چنین خطاهایی را کاهش می‌دهد، ولی تضمین نمی‌کند که در هر نمونه حذف شوند.

ایده یادگیری فیزیک‌آگاه، ورود دانسته‌های ساختاری به فرایند یادگیری است. در صورت‌بندی اولیه شبکه‌های عصبی فیزیک‌آگاه، باقیمانده معادلات حاکم به تابع آموزش افزوده می‌شود [3]. مرورهای جدیدتر نشان می‌دهند که فیزیک می‌تواند علاوه بر جریمه، در معماری و پارامتردهی خروجی نیز وارد شود [4]. در مسئله حاضر، معادله توازن توان و دینامیک باتری جبری و گسسته‌اند، نه معادلات دیفرانسیل جزئی؛ بنابراین هدف، حل مستقیم مسئله‌های مطرح‌شده در مقاله رئیسی و همکاران نیست، بلکه اقتباس کنترل‌شده از ایده فیزیک‌آگاه برای تصمیم‌گیری ساعتی ریزشبکه است.

۱-۲ مسئله تحقیق

در گام زمانی t ، بار $P_L(t)$ ، توان در دسترس فتوولتائیک $P_{PV}(t)$ ، قیمت خرید و فروش و وضعیت شارژ باتری معلوم‌اند. تصمیم بهره‌برداری شامل توان شبکه $P_G(t)$ ، توان شارژ $P_c(t)$ ، توان دشارژ $P_d(t)$ و وضعیت شارژ گام بعد است. قرارداد علامت در این گزارش چنین است: $P_G > 0$ به معنی خرید از شبکه و $P_G < 0$ به معنی فروش است؛ P_d و P_c باید نامنفی باشند.

در نسخه ابتدایی این پروژه، قیود باتری فقط به شکل جریمه نرم بودند و در ارزیابی نیز تنها نرخ نقض SOC گزارش می‌شد. این رویکرد دو ایراد داشت: نخست، ممکن بود توان شارژ یا دشارژ منفی شود؛ دوم، امکان شارژ و دشارژ هم‌زمان وجود داشت. در نسخه بازنگری‌شده، شبکه فیزیک‌تعبیه‌شده یک فرمان علامت‌دار باتری تولید می‌کند و بقیه خروجی‌ها از یک نداشت فیزیکی قطعی ساخته می‌شوند. در نتیجه، توازن توان، سقف توان باتری، نامنفی بودن توان‌ها، عدم شارژ/دشارژ هم‌زمان و حدود SOC به‌صورت ساختاری اعمال می‌شوند.

۱-۳ هدف و پرسش‌های تحقیق

هدف اصلی، ارزیابی این پرسش است که آیا پارامتردهی فیزیکی خروجی می‌تواند یک شبکه عصبی کوچک را به کنترل‌کننده‌ای همواره قابل اجرا برای ریزشبکه متصل به شبکه تبدیل کند یا خیر. هدف اقتصادی، جایگزینی قطعی حل‌کننده بهینه‌سازی نیست؛ بلکه تقریب سریع یک برنامه مرجع و سنجش هزینه ناشی از این تقریب است. پرسش‌های تحقیق عبارت‌اند از:

۱. چگونه می‌توان خروجی شبکه را چنان پارامتری کرد که قيود باتری و توازن توان در همه گام‌ها برقرار باشند؟
۲. تفاوت شبکه داده‌محور آزاد و شبکه فیزیک‌تعبیه‌شده از نظر باقیمانده توازن، نقض قيود و هزینه اجرایی چیست؟
۳. فاصله هزینه کنترل‌کننده یادگرفته‌شده از یک مرجع برنامه‌ریزی پویا روی داده عمومی چقدر است؟

۱-۴ سهم کار

سهم این پروژه در چهار بخش خلاصه می‌شود:

۱. تبدیل قيود توازن و باتری به یک لایه خروجی قطعی، به‌جای اتکای صرف به جریمه نرم؛
 ۲. استفاده از مرجع برنامه‌ریزی پویا برای تولید برنامه مقید و مقایسه اقتصادی؛
 ۳. اجرای آزمون بازگشتی روی SOC پیش‌بینی‌شده خود مدل، نه فقط ارزیابی یک گامی با SOC واقعی؛
 ۴. ساخت مطالعه موردی شفاف و بازتولیدپذیر از بار عمومی، تابش عمومی و فرض‌های مهندسی صریح.
- مقاله اولادجو و فولی [1] برای آشنایی با مسئله ریزشبکه متصل به شبکه و متغیرهای توان مفید بوده است، اما نظریه بازی، تخصیص سود و حل چنددلی‌نفعه آن مقاله در این پژوهش نه پیاده‌سازی شده و نه ادعا می‌شود. محدود نگه داشتن دامنه به یک ریزشبکه در یک مکان، انتخابی آگاهانه است تا ادعاها با آزمایش‌ها هم‌خوان بمانند.

۱-۵ داده و قلمرو

سیگنال بار از مجموعه داده عمومی مصرف وسایل و روشنایی یک خانه کم‌مصرف گرفته شده است [6], [5]. تابش روزانه سطح زمین از خدمت NASA POWER دریافت شده است [7]. این دو منبع با یک مدل PV، بار زمینه ثابت و تعرفه زمان استفاده ترکیب شده‌اند. بنابراین مطالعه موردی، داده عمومی ترکیبی است و نه اندازه‌گیری یک ریزشبکه کامل در محل. هیچ ادعایی درباره عملکرد صنعتی، پایداری گذرا، کیفیت توان، تخریب واقعی باتری یا تعمیم به همه مصرف‌کنندگان مطرح نمی‌شود.

مدل باتری یک مدل انرژی گسسته با بازده ثابت است. دینامیک مبدل، محدودیت شبکه توزیع، عدم قطعیت پیش‌بینی و کنترل چندعامل خارج از قلمرو هستند. برای آن که مقایسه یادگیری منصفانه باشد، داده‌ها به ترتیب زمانی به آموزش، اعتبارسنجی و آزمون با نسبت ۶۰، ۲۰ و ۲۰ درصد افراز می‌شوند و داده آزمون در انتخاب epoch به کار نمی‌رود.

۱-۶ ساختار گزارش

فصل ۲ مدل ریز شبکه، پیشینه و قیود را معرفی می کند. فصل ۳ مرجع برنامه ریزی پویا، دو شبکه و شاخص های ارزیابی را توضیح می دهد. در فصل ۴ منشأ داده، تنظیمات اجرا و نتایج آزمون گزارش می شوند. فصل ۵ جمع بندی و مسیرهای ادامه کار را ارائه می کند.

فصل ۲

مبانی نظری و پیشینه پژوهش

۲-۱ مدل ریزشبه متصل به شبکه

ریزشبه مورد مطالعه شامل بار محلی، منبع فتوولتائیک، باتری و اتصال به شبکه بالادست است. در هر گام زمانی، توان بار و تولید PV برون‌زادند و کنترل‌کننده فقط درباره استفاده از باتری و تبادل با شبکه تصمیم می‌گیرد. این سطح از مدل‌سازی، بهره‌برداری انرژی را توصیف می‌کند و جایگزین تحلیل گذرای ولتاژ، فرکانس یا حفاظت نیست. در گام t ، نمادها چنین‌اند:

- $P_L(t)$: توان بار، بر حسب کیلووات؛
- $P_{PV}(t)$: توان فتوولتائیک در دسترس، نامنفی؛
- $P_G(t)$: توان خالص شبکه؛ مثبت برای خرید و منفی برای فروش؛
- $P_c(t)$ و $P_d(t)$: توان شارژ و دشارژ باتری، هر دو نامنفی؛
- $s(t)$: نسبت انرژی ذخیره‌شده به ظرفیت نامی باتری؛
- $c_b(t)$ و $c_s(t)$: قیمت خرید و فروش برق.

نمادگذاری توان و تفکیک لایه بهره‌برداری از لایه‌های اقتصادی گسترده‌تر با مسئله ریزشبه متصل به شبکه هم‌راستا است [1]. با این حال، در این گزارش فقط یک بهره‌بردار و یک اتصال شبکه وجود دارد.

۲-۲ توازن توان و دینامیک باتری

قانون بقای توان در هر گام به صورت

$$P_G(t) + P_{PV}(t) + P_d(t) = P_L(t) + P_c(t) \quad (2-1)$$

نوشته می‌شود. باقیمانده متناظر برای ارزیابی مدل آزاد برابر است با

$$r_G(t) = P_G(t) + P_{PV}(t) + P_d(t) - P_c(t) - P_L(t). \quad (2-2)$$

رفتار باتری با مدل انرژی گسسته زیر تقریب زده می‌شود:

$$s(t + \Delta t) = s(t) + \frac{\eta_c P_c(t) \Delta t}{E_{\max}} - \frac{P_d(t) \Delta t}{\eta_d E_{\max}}, \quad (2-3)$$

که در آن $E_{\max}$ بر حسب کیلووات‌ساعت، $\Delta t = 1 \text{ h}$ و η_c و η_d بازده شارژ و دشارژ هستند. حدهای ایمنی عبارت‌اند از

$$s_{\min} \leq s(t) \leq s_{\max}, \quad 0 \leq P_c(t), P_d(t) \leq P_{\max}. \quad (2-4)$$

همزمانی شارژ و دشارژ برای یک باتری تک‌مبدله مجاز نیست؛ بنابراین قید انحصار باید در همه گام‌ها برقرار باشد:

$$P_c(t)P_d(t) = 0. \quad (2-5)$$

۲-۳ هزینه بهره‌برداری

هزینه یک گام شامل هزینه خرید، درآمد فروش و یک جریمه کوچک برای عبور انرژی از باتری است:

$$g_t = c_b(t)[P_G(t)]_+\Delta t - c_s(t)[-P_G(t)]_+\Delta t + \kappa(P_c(t) + P_d(t))\Delta t. \quad (2-6)$$

وجود Δt یکدستی واحدهای هزینه را حفظ می‌کند و رابطه را به گام یک‌ساعته محدود نمی‌کند. در مدل حاضر، κ نماینده‌ای ساده‌شده از استهلاک عبوری باتری است، نه مدل الکتروشیمیایی واقعی. مدل‌های بهینه‌سازی بهره‌برداری نیز معمولاً هزینه انرژی را با حدهای توان و SOC باتری همراه می‌کنند [2].

۲-۴ یادگیری فیزیک‌آگاه و قید سخت

در چارچوب PINN متداول، یک شبکه خروجی آزاد تولید می‌کند و باقیمانده معادلات فیزیکی به تابع آموزش افزوده می‌شود [3]. مزیت آن، پیوند داده و مدل است؛ اما جریمه نرم با ضریب محدود، به‌تنهایی تضمین نمی‌کند که خروجی نهایی دقیقاً قید را رعایت کند. این مسئله در کاربردهای مهندسی اهمیت دارد، زیرا حتی نقض کوچک SOC یا تولید توان با علامت نامعتبر می‌تواند فرمان را غیرقابل اجرا کند.

یک مسیر مکمل، وارد کردن قید در خود معماری است. پژوهش‌های قید سخت نشان داده‌اند که لایه‌های تحلیلی یا فزاینده می‌توانند بعضی قیود را دقیقاً تضمین کنند [9], [8]. در این کار از همین ایده برای قیود جبری ریزشبکه استفاده می‌شود. این روش یک PINN حل‌کننده PDE نیست؛ تعبیر دقیق‌تر آن physics-embedded learning یا یادگیری فیزیک‌تعبیه‌شده است. این نام‌گذاری از بزرگ‌نمایی روش جلوگیری می‌کند.

۲-۵ جایگاه کار در پیشینه

۲-۵-۱ مدیریت انرژی مبتنی بر بهینه‌سازی

روش‌های کلاسیک مدیریت انرژی، مسئله بهره‌برداری را به‌صورت برنامه‌ریزی خطی یا آمیخته عدد صحیح، برنامه‌ریزی پویا، یا کنترل پیش‌بین مدل صورت‌بندی می‌کنند. برنامه‌ریزی پویا با رابطه بلمن، تصمیم جاری را به هزینه آینده پیوند می‌دهد [10]؛ در مقابل، MILP برای نمایش تصمیم‌های گسسته و MPC برای بازبهینه‌سازی افق لغزان مناسب‌اند. مطالعات موردی ریزشبکه نشان داده‌اند که MPC/MILP می‌تواند هزینه و قیود بهره‌برداری را در یک صورت‌بندی صریح ترکیب کند [12], [11], [2]. این روش‌ها مرجع‌هایی تفسیرپذیر فراهم می‌کنند، اما هزینه حل آن‌ها به طول افق، تفکیک شبکه حالت، سناریوها و جزئیات مدل وابسته است. برنامه‌ریزی پویای این گزارش نیز مرجع گسسته است و ادعای بهینگی پیوسته ندارد.

۲-۵-۲ مدیریت انرژی مبتنی بر یادگیری

یادگیری تقویتی، سیاست کنترل را از تعامل با محیط می‌آموزد و شبکه‌های عصبی نیز می‌توانند به صورت جانشین نظارت‌شده، نگاشت خروجی یک حل‌کننده را تقریب بزنند. مرور کاربرد یادگیری تقویتی در پاسخ‌گویی بار، ظرفیت این روش‌ها و در عین حال دشواری ارزیابی و تعمیم را نشان می‌دهد [13]. در این پروژه مسیر دوم دنبال می‌شود: برچسب‌ها از برنامه‌ریزی پویا می‌آیند و شبکه با بهینه‌ساز آدام آموزش می‌بیند [14]. مسئله مشترک آن است که خروجی آزاد یا سیاست یادگرفته‌شده، بدون سازوکار اضافی لزوماً توازن توان، حدود SOC و انحصار شارژ/دشارژ را رعایت نمی‌کند؛ بنابراین خطای تقلید کم به تنهایی گواه امکان‌پذیری نیست.

۲-۵-۳ اعمال قید در کنترل‌کننده‌های یادگرفته‌شده

در یادگیری تقویتی ایمن، مسئله را می‌توان به شکل فرایند تصمیم‌گیری مارکوف مقید نوشت [15] و قید را با بهینه‌سازی سیاست مقید یا توابع لیاپانوف وارد کرد [17], [16]. بنچمارک‌های اکتشاف ایمن نیز تأکید می‌کنند که پاداش و ایمنی باید جداگانه گزارش شوند [18]. روش‌های جریمه‌ای ساده‌ترند، اما رعایت قید به وزن جریمه و کیفیت آموزش وابسته می‌ماند [19].

راه دیگر، محدود کردن مستقیم فضای خروجی است. OptNet یک برنامه درجه‌دو تفکیک‌پذیر را به صورت لایه شبکه وارد می‌کند [20] و شبکه‌های محدب نسبت به ورودی، ساختاری را فراهم می‌کنند که بهینه‌سازی روی برخی ورودی‌ها محذب بماند [21]. معماری‌های قید سخت نیز قید را با بازپارامتردهی یا لایه تحلیلی اعمال می‌کنند [9], [8]. انتخاب حاضر از این خانواده است، ولی حل‌گر بهینه‌سازی تفکیک‌پذیر یا ICNN نیست: یک نگاشت بسته و بدون پارامتر، تنها فرمان باتری را به چهار کمیت قابل اجرا تبدیل می‌کند. این سادگی مخصوص قیود جبری مدل حاضر است و برتری عمومی نسبت به روش‌های ایمن دیگر ادعا نمی‌شود.

۲-۵-۴ یادگیری فیزیک‌آگاه در سامانه‌های انرژی

در PINN‌های متعارف، باقیمانده معادله دیفرانسیل در تابع آموزش ظاهر می‌شود [3] و چارچوب گسترده‌تر یادگیری فیزیک‌آگاه، ورود دانش فیزیکی از راه داده، زیان یا معماری را دربر می‌گیرد [4]. با این حال، مسئله این گزارش حل یک PDE نیست. توازن توان و گذار ساعتی باتری روابط جبری و گسسته‌اند و در لایه خروجی دقیقاً محاسبه می‌شوند، نه آن‌که باقیمانده آن‌ها فقط کمینه شود. از این رو، اصطلاح دقیق‌تر برای روش حاضر «شبکه فیزیک‌تعبیه‌شده» است؛ صفر شدن نقض‌های تعریف‌شده خاصیت طراحی این نگاشت است، نه کشف آماری.

جدول ۱-۲. مقایسه رویکردهای تولید برنامه انرژی

رویکرد	داده/مدل لازم	وضعیت قیدها	نقش در این پروژه
برنامه‌ریزی پویا	مدل و افق برون‌زاد	مقید، تا دقت شبکه حالت	مرجع اقتصادی
شبکه داده‌محور آزاد	نمونه برچسب‌دار	تضمینی ندارد	baseline یادگیری
PINN با جریمه نرم	نمونه و باقیمانده قانون	وابسته به وزن جریمه	انگیزه روش شناختی
شبکه فیزیک‌تعبیه‌شده	نمونه و نگاشت فیزیکی	سخت، برای قیود مدل‌شده	مدل پیشنهادی

۲-۶ مرجع برنامه‌ریزی پویا

برای آن که شبکه فقط یک قاعده حریصانه را تقلید نکند، برنامه مرجع با برنامه‌ریزی پویا ساخته می‌شود. حالت، SOC و فرمان، توان علامت‌دار باتری است. اگر $V_t(s)$ کمینه هزینه آینده از زمان t باشد، رابطه بازگشتی چنین است:

$$V_t(s) = \min_{u \in \mathcal{U}(s)} \{g_t(s, u) + V_{t+1}(f(s, u))\}, \quad (2-7)$$

که f همان دینامیک (۲-۳) و $\mathcal{U}(s)$ مجموعه فرمان‌های مجاز در SOC فعلی است. در پیاده‌سازی حاضر شرط نهایی $V_T(s) = 0$ برای همه نقاط شبکه وضعیت در نظر گرفته شده است؛ بنابراین ارزش بازیافت یا هدف نهایی جداگانه‌ای برای باتری اعمال نمی‌شود. SOC در مرجع روی شبکه‌ای با گام ۰٫۱ رگسسته می‌شود؛ بنابراین مرجع، تقریب عددی یک حل‌کننده افق کامل با آینده‌نگری کامل است، نه بهینه دقیق پیوسته.

۲-۷ جمع‌بندی فصل


این فصل قیود اصلی و شاخص هزینه را مشخص کرد. تفاوت اساسی نسخه بازنگری شده با مدل آزاد آن است که امکان‌پذیری تنها یک معیار پس از آموزش نیست؛ در شبکه فیزیک تعبیه شده، بخشی از تعریف خروجی است. فصل بعد نحوه ساخت داده، معماری و آزمون بازگشتی را دقیق می‌کند.

فصل ۳

روش‌شناسی

۳-۱ جریان کلی آزمایش

شکل ۳-۱ جریان آزمایش را نشان می‌دهد. ابتدا از سری بار و PV، برنامه مرجع مقید با برنامه‌ریزی پویا ساخته می‌شود. سپس دو شبکه با این داده آموزش می‌بینند. تفاوت آن دو در نحوه تعریف خروجی است: شبکه داده‌محور چهار خروجی آزاد می‌دهد، اما شبکه فیزیک‌تعبیه‌شده فقط فرمان باتری را می‌سازد و همه متغیرهای دیگر از قوانین فصل قبل حاصل می‌شوند. در انتها، هر دو مدل روی افق آزمون با SOC تولیدشده توسط خودشان بازگشت داده می‌شوند.



شکل ۳-۱. جریان مطالعه موردی و مقایسه کنترل‌کننده‌ها

۳-۲ بردار ورودی و مرجع آموزشی

برای ساعت t ، بردار ورودی شامل زمان تناوبی، وضعیت روز، بار، PV، تعرفه، SOC و پنجره پیش‌بینی کوتاه است:

$$\mathbf{x}(t) = (\sin(2\pi h/24), \cos(2\pi h/24), d, P_L, P_{PV}, c_b, c_s, s, P_L^{t+1}, P_{PV}^{t+1}, P_L^{t+3}, P_{PV}^{t+3}). \quad (3-1)$$

h ساعت روز و d نشانگر روز کاری است. مقادیر یک و سه ساعت آینده، پیش‌بینی بی‌خطا فرض می‌شوند. این فرض برای مقایسه آفلاین با برنامه مرجع است و ادعای دسترسی بی‌خطا به پیش‌بینی در میدان نیست. برنامه‌ریزی پویا با مشاهده کل افق برون‌زاد، دنباله مرجع

$$\mathbf{y}^*(t) = (P_G^*, P_c^*, P_d^*, s^*(t + \Delta t)) \quad (3-2)$$

را می‌سازد. آماره‌های استانداردسازی، یعنی میانگین و انحراف معیار، فقط از مجموعه آموزش محاسبه می‌شوند تا از نشت آماری مجموعه اعتبارسنجی و آزمون جلوگیری شود.

۳-۳ شبکه داده‌محور آزاد

مدل نخست یک شبکه پیش‌خور با دو لایه پنهان ۳۲ واحدی و فعال‌ساز تانژانت هیپربولیک است. خروجی آن چهار مؤلفه (۳-۲) را مستقیماً پیش‌بینی می‌کند. تابع آموزش آن میانگین مربع خطای خروجی استاندارد شده است. این مدل برای آن در نظر گرفته شده که نشان دهد نزدیک بودن به برچسب، به تنهایی معادل قابل اجرا بودن برنامه نیست.

خروجی خام برای سنجش نقض‌ها با SOC پیش‌بینی شده خود مدل بازگشت داده می‌شود. در زنجیره اجرایی ترمیم‌شده، SOC ورودی هر گام از فرمان نگاشت‌یافته و دینامیک باتری دوباره محاسبه می‌شود و نه از مؤلفه خام SOC شبکه. برای محاسبه هزینه منصفانه، فرمان خام مدل داده‌محور با نگاشت ایمنی پس‌پردازشی $u_{\text{safe}} = \text{clip}(\hat{P}_c - \hat{P}_d, -P_{\text{max}}, P_{\text{max}})$ به لایه (۳-۶) داده می‌شود. هزینه حاصل با برچسب «داده‌محور با نگاشت ایمنی» گزارش می‌شود و نباید با هزینه خروجی خام احتمالاً ناممکن اشتباه گرفته شود.

۳-۴ شبکه فیزیک‌تعبیه‌شده

شبکه دوم همان عرض و عمق لایه‌های پنهان را دارد، ولی به جای چهار خروجی آزاد، فقط یک عدد $z(t)$ می‌سازد. فرمان علامت‌دار باتری از رابطه

$$u(t) = P_{\text{max}} \tanh(z(t)) \quad (3-3)$$

به دست می‌آید؛ علامت مثبت برای شارژ و منفی برای دشارژ است. سقف وابسته به SOC برای شارژ و دشارژ چنین تعریف می‌شود:

$$\begin{aligned} \bar{P}_c(s) &= \min \left(P_{\text{max}}, \frac{(s_{\text{max}} - s)E_{\text{max}}}{\eta_c \Delta t} \right), \\ \bar{P}_d(s) &= \min \left(P_{\text{max}}, \frac{(s - s_{\text{min}})E_{\text{max}}\eta_d}{\Delta t} \right). \end{aligned} \quad (3-4)$$

سپس خروجی‌ها به صورت

$$P_c = \min([u]_+, \bar{P}_c(s)), \quad P_d = \min([-u]_+, \bar{P}_d(s)) \quad (3-5)$$

$$s(t + \Delta t) = s(t) + \frac{\eta_c P_c \Delta t}{E_{\max}} - \frac{P_d \Delta t}{\eta_d E_{\max}}, \quad (3-6)$$

$$P_G = P_L + P_c - P_{PV} - P_d$$

ساخته می‌شوند. در این مطالعه برای P_G سقف واردات یا صادرات در نظر گرفته نشده است؛ این انتخاب مدل سازی باعث می‌شود توازن توان پس از تعیین فرمان باتری همواره با تبادل شبکه بسته شود.

از (3-5) روشن است که در هر گام حداکثر یکی از P_c و P_d مثبت است. از (3-4) و (3-6) نیز حدود SOC و توازن توان برقرار می‌شوند. بنابراین باقیمانده‌های (2-2) و دینامیک SOC در این مدل باید، به جز خطای گرد کردن، صفر باشند. تابع آموزش این شبکه خطای فرمان مرجع است:

$$\mathcal{L}_u = \frac{1}{N} \sum_{i=1}^N \left(\tanh(z_i) - \frac{u_i^*}{P_{\max}} \right)^2. \quad (3-7)$$

این ساختار از نظر مفهومی با یادگیری فیزیک آگاه همخوان است، اما اصطلاح دقیق آن در این گزارش «فیزیک تعبیه شده با قید سخت» است. مزیت آن نسبت به جریمه نرم این است که وزن جریمه برای تضمین قیود اساسی لازم نیست.

3-5 تنظیم آموزش و افراز داده

نمونه‌ها به ترتیب زمانی می‌مانند: 60 درصد اول آموزش، 20 درصد بعدی اعتبارسنجی و 20 درصد پایانی آزمون‌اند. شبکه‌ها با الگوریتم Adam، دسته‌های 64 تایی و حداکثر 450 epoch آموزش می‌بینند. توقف زودهنگام با صبر 55 epoch فقط بر خطای اعتبارسنجی اعمال می‌شود. پنج بذر 7، 11، 19، 23 و 29 فقط مقداره‌ی اولیه و ترتیب دسته‌ها را تغییر می‌دهند. در نتیجه، انحراف معیار جدول نتایج پراکندگی آموزش را نشان می‌دهد، نه تغییر خود داده یا تغییر تقسیم داده.

3-6 شاخص‌های ارزیابی

برای شفافیت، MSE تجمعی در این گزارش صریحاً میانگین روی چهار مؤلفه خروجی است:

$$\text{MSE}_{\text{comp}} = \frac{1}{4N} \sum_{i=1}^N \sum_{j=1}^4 (\hat{y}_{ij} - y_{ij}^*)^2. \quad (3-8)$$

از آن جا که توان و SOC هم‌واحد نیستند، این عدد به‌تنهایی معیار فیزیکی کافی نیست. به همین دلیل، میانگین قدرمطلق خطای توان شبکه، فرمان باتری و SOC نیز جداگانه گزارش می‌شوند.

امکان‌پذیری با پنج شاخص کنترل می‌شود: میانگین $|r_G|$ ، نرخ نقض SOC، نرخ توان شارژ منفی، نرخ توان دشارژ منفی و نرخ شارژ/دشارژ هم‌زمان. برای هر برنامه قابل اجرا، هزینه کل آزمون نیز از جمع (2-6) محاسبه می‌گردد. مرجع برنامه‌ریزی پویا و حالت بدون باتری، دو مرز قابل تفسیر برای هزینه هستند.

فصل ۴

پیاده‌سازی و تحلیل نتایج

۴-۱ داده عمومی و قابلیت بازتولید

آزمایش با ۳۲۸۹ رکورد ساعتی، از ساعت ۱۷ روز ۱۱ ژانویه تا ساعت ۱۷ روز ۲۷ مه ۲۰۱۶، انجام شده است. این تعداد پس از میانگین‌گیری ساعتی و نگه‌داشتن ساعت‌های کامل به دست آمده و با بازه ثبت‌شده در متادیتا سازگار است. منشأ داده و هر تبدیل در فایل metadata.json (در شاخه code/data) ثبت شده‌اند. جدول ۴-۱ تفاوت مهم میان «داده عمومی» و «داده میدانی ریزش‌بکه» را روشن می‌کند.

جدول ۴-۱. منشأ مؤلفه‌های مطالعه موردی

مؤلفه	منشأ و تبدیل	محدودیت
بازه و شمار رکورد	۱۱ ژانویه ۲۰۱۶، ساعت ۱۷ تا ۲۷ مه ۲۰۱۶، ساعت ۱۷؛ رکورد ۳۲۸۹	بازه پردازش‌شده است و نباید با بازه کامل مجموعه اصلی یکسان فرض شود
بار	میانگین ساعتی مصرف وسایل و روشنایی UCI، به‌علاوه بار زمینه ۰٫۲۰ kW	بار کامل یک محله یا ریزش‌بکه نیست
PV	تابش روزانه NASA POWER، توزیع‌شده با پوش ارتفاع خورشید؛ PV نامی ۱ kW و نسبت عملکرد ۰٫۸۲	توان PV ساعتی اندازه‌گیری شده در همان خانه نیست
تعرفه	تعرفه زمان‌استفاده مستند در کد	قیمت بازار واقعی یا قبض مشترک نیست
باتری	مدل انرژی با ظرفیت ۲ kWh	دما، پیری و محدودیت مبدل ندارد

داده اصلی UCI، اندازه‌گیری مصرف وسایل و روشنایی خانه کم‌مصرف را در دوره‌های ده‌دقیقه‌ای فراهم می‌کند [6]، [5]. از میان هر شش نمونه، فقط ساعت‌های کامل نگه داده شده‌اند. تابش ALLSKY-SFC- SW-DWN نیز از NASA POWER گرفته شده است [7]. پس از این دو تبدیل، مجموعه حاصل یک مطالعه موردی ترکیبی و بازتولیدپذیر است؛ در نتیجه عنوان «آزمون داده میدانی ریزش‌بکه» برای آن نادرست خواهد بود.

کد شبیه‌سازی، اسکرپت آماده‌سازی داده و آزمون لایه فیزیکی در شاخه code پروژه قرار دارند. اجرای آزمون لایه فیزیکی، در حالت‌های حدی SOC و فرمان باتری، توازن توان، سقف توان، نامفی بودن توان‌ها و عدم شارژ/دشارژ هم‌زمان را کنترل می‌کند.

۴-۲ تنظیمات اجرا

از ۳۲۸۹ ساعت، ۱۹۷۳ ساعت برای آموزش، ۶۵۷ ساعت برای اعتبارسنجی و ۶۵۹ ساعت پایانی برای آزمون اختصاص یافت. این افراز کاملاً زمانی است. هر دو شبکه دو لایه پنهان ۳۲ واحدی دارند. شبکه داده‌محور چهار خروجی و شبکه فیزیک تعبیه‌شده یک خروجی فرمان دارد. بیشینه آموزش epoch ۴۵۰ و اندازه دسته ۶۴ است؛ بهترین epoch هر بذر فقط با خطای اعتبارسنجی انتخاب می‌شود.

مرجع برنامه‌ریزی پویا SOC را با گام ۰٫۰۱ در بازه [۰٫۲۰، ۰٫۹۰] و فرمان باتری را با ۴۱ مقدار در بازه [۱، -۱] kW جست‌وجو می‌کند. بنابراین مقدار مرجع، بهینه‌سازی پیوسته دقیق نیست؛ با این حال، یک baseline مقید، صریح و مستقل از شبکه عصبی فراهم می‌کند.

۴-۳ نتایج دقت و قیود

جدول ۴-۲ خطای تقریب نسبت به برنامه مرجع را نشان می‌دهد. MSE مطابق (۳-۸) میانگین چهار مؤلفه است و فقط برای مقایسه عددی استفاده می‌شود؛ شاخص‌های MAE با واحدهای جداگانه، تفسیرپذیرترند. مدل داده‌محور آزاد، MSE پایین‌تری دارد، اما این مزیت به معنای قابل اجرا بودن فرمان نیست.

جدول ۴-۲. میانگین و انحراف معیار پنج بذر روی افق آزمون


مدل	MSE _{comp}	MAE(P_G) (kW)	MAE(u) (kW)	MAE(s)
مرجع DP	۰	۰	۰	۰
بدون باتری	۰٫۰۶۷۶	۰٫۱۱۷	۰٫۱۱۷	۰٫۳۷۷
داده‌محور خام	۰٫۰۰۸۲ ± ۰٫۰۰۰۸	۰٫۰۵۸ ± ۰٫۰۰۰۴	۰٫۰۶۵ ± ۰٫۰۰۰۴	۰٫۰۹۴ ± ۰٫۰۰۰۶
فیزیک تعبیه‌شده	۰٫۰۰۹۱ ± ۰٫۰۰۰۱۴	۰٫۰۶۷ ± ۰٫۰۰۰۴	۰٫۰۶۷ ± ۰٫۰۰۰۴	۰٫۰۹۶ ± ۰٫۰۰۱۱

جدول ۴-۳ علت کافی نبودن MSE را آشکار می‌کند. در خروجی خام مدل داده‌محور، حدود ۷٫۱٪ از SOC‌ها نامعتبرند و به ترتیب ۳۰٫۳٪ و ۳۱٫۷٪ از مقادیر شارژ و دشارژ منفی‌اند. در حدود ۴۰٫۹٪ از گام‌ها نیز هر دو توان شارژ و دشارژ مثبت‌اند. در مقابل، لایه فیزیک تعبیه‌شده همه این نرخ‌ها را در محاسبه شناور به صفر می‌رساند، زیرا قیدها در خود خروجی اعمال شده‌اند. صفر بودن باقیمانده این مدل یک کشف آماری نیست؛ خاصیت طراحی معماری است و باید همین‌گونه تفسیر شود.


جدول ۴-۳. شاخص‌های امکان‌پذیری روی مجموعه آزمون

مدل	$\overline{ r_G }$ (kW)	نقض SOC (%)	$P_c < 0$ (%)	$P_d < 0$ (%)	هم‌زمانی (%)
مرجع DP	≈ ۰	۰	۰	۰	۰
بدون باتری	≈ ۰	۰	۰	۰	۰
داده‌محور خام	۰٫۰۲۸۶ ± ۰٫۰۰۰۶۰	۷٫۱ ± ۳٫۲	۳۰٫۳ ± ۴٫۶	۳۱٫۷ ± ۸٫۸	۴۰٫۹ ± ۹٫۱
فیزیک تعبیه‌شده	≈ ۰	۰	۰	۰	۰

شکل ۴-۲ قدرمطلق باقیمانده توازن را در هفته نخست آزمون نشان می‌دهد. شکل ۴-۱ نیز اولین روز آزمون را نمایش می‌دهد؛ برخلاف نسخه پیشین، این شکل از داده آموزش یا اعتبارسنجی انتخاب نشده است.



شکل ۴-۱. بار و PV مطالعه موردی و SOC کنترل‌کننده‌ها در نخستین روز آزمون



شکل ۴-۲. قدر مطلق باقیمانده توازن توان در هفته نخست آزمون


۴-۴ هزینه اجرایی

هزینه کل افق آزمون ۶۵۹ ساعته در جدول ۴-۴ آمده است. هزینه مدل داده‌محور فقط پس از نگاشت ایمنی پس‌پردازشی محاسبه شده؛ بنابراین مقدار آن پاداشی برای نقض قیدهای خام نیست. شبکه فیزیک تعبیه‌شده با هزینه $۰,۲۴۲ \pm ۱۷,۱۸۶$ ، حدود $۲۱,۴\%$ ارزان‌تر از حالت بدون باتری است و به‌طور میانگین $۱۱,۶\%$ از مرجع DP گران‌تر می‌ماند. هزینه آن با نسخه ترمیم‌شده مدل داده‌محور ($۰,۴۹۲ \pm ۱۷,۵۲۹$) قابل مقایسه و به‌طور میانگین اندکی کمتر است؛ با توجه به پنج بذر و پراکندگی مشاهده‌شده، این تفاوت معنادار نیست. این شکاف نشان می‌دهد که امکان‌پذیری تضمین‌شده به معنی رسیدن خودکار به بهینه افق کامل نیست.

اندازه‌گیری زمان روی محیط محاسباتی این بازنگری (پردازنده x86_64 که مدل دقیق آن در کانتینر آشکار نشده، پایتون ۲٫۱٫۳ و NumPy نسخه ۱٫۲۰٫۴) انجام شد. حل یک‌باره مرجع DP برای افق کامل ۳۲۸۹ گام، ۷٫۸۷۶ ثانیه طول کشید. زمان یک گام کنترل‌کننده، شامل ساخت ویژگی، استانداردسازی، گذر پیش‌رو در شبکه ۳۲×۲ ، نگاشت tanh و لایه تحلیلی، پس از ۱۰۰۰ فراخوانی گرم‌سازی و در ۱۰ تکرار ۱۰۰۰۰ تا، $۰,۲۸۷ \pm ۱۸,۶۷۰$ میکروثانیه بود. این اعداد فقط مشخصه همین محیط‌اند و با فرمان python `code/benchmark_runtime.py` بازتولید می‌شوند؛ برای گزارش روی سخت‌افزار مقصد باید همین پروتکل اجرا و نوع پردازنده/شتاب‌دهنده، میانگین، انحراف معیار و تعداد فراخوانی‌ها ثبت شود.

جدول ۴-۴. هزینه اجرایی افق آزمون؛ واحد پولی مفروض

مدل	هزینه کل آزمون	فاصله از مرجع DP (%)
مرجع DP	۱۵,۴۰۶	۰
بدون باتری	۲۱,۸۷۶	۴۲,۰
داده‌محور با نگاشت ایمنی پس‌پردازشی	$۰,۴۹۲ \pm ۱۷,۵۲۹$	$۱۳,۸ \pm ۳,۲$
فیزیک تعبیه‌شده	$۰,۲۴۲ \pm ۱۷,۱۸۶$	$۱۱,۶ \pm ۱,۶$



شکل ۴-۳. میانگین هزینه روزانه برنامه‌های قابل اجرا روی افق آزمون

۴-۵ تفسیر و محدودیت‌ها

نتیجه اصلی این آزمایش، صرفاً کاهش خطای میانگین نیست. شبکه فیزیک تعبیه شده با اندکی افزایش خطای تقلید نسبت به مدل آزاد، برنامه‌ای تولید می‌کند که از نظر قیود تعریف شده همواره قابل اجراست. در مقابل، مدل آزاد برای استفاده عملی به تعمیر پس‌پردازشی نیاز دارد. این موازنه با ادبیات قید سخت سازگار است: محدود کردن فضای خروجی، آزادی تقریب را کم می‌کند اما قابلیت اعتماد فیزیکی را افزایش می‌دهد [9], [8].

محدودیت‌های نتیجه نیز مهم‌اند: داده ترکیبی است، تابش PV ساعتی اندازه‌گیری نشده و ورودی‌های یک و سه ساعت آینده و افق مرجع DP با آینده‌نگری کامل فراهم شده‌اند. تبادل شبکه نامحدود فرض شده است؛ در کاربرد دارای سقف اتصال، لایه سخت باید فرمان باتری را با بازه مجاز P_G سازگار کند یا یک گیره تحلیلی برای P_G و قاعده تخصیص کمبود/مازاد داشته باشد. مدل باتری نیز دما، پیری، وابستگی بازده به توان و دینامیک مبدل را دربر نمی‌گیرد. از این‌رو، گزارش حاضر برتری در بهره‌برداری صنعتی یا عملکرد در حضور خطای پیش‌بینی را نشان نمی‌دهد.

آنچه در ادامه می‌آید، صرفاً پروتکل پیشنهادی کارهای آینده است، نه نتیجه آزمایش شده: هر بار فقط یکی از $E_{\max}$ ، $P_{\max}$ ، بازده‌ها، K و فاصله قیمت خرید/فروش در یک شبکه از پیش ثبت شده تغییر کند؛ برای هر حالت مرجع و پنج بذر دوباره اجرا و هزینه، فاصله از DP و نقض‌ها گزارش شود. سپس ورودی‌های نگاه‌به‌جلو $t + 1$ و $t + 3$ به صورت جداگانه و هم‌زمان حذف شوند؛ پیش‌بینی‌ها با خطاهای کالیبره شده جایگزین گردند؛ و روزهای خارج از توزیع برحسب فصل یا صدک بار کنار گذاشته و فقط برای آزمون استفاده شوند. منحنی آموزش باید زیان آموزش و اعتبارسنجی هر بذر و نقطه توقف را نشان دهد. تحلیل رژیمی نیز ساعت‌های نزدیک $s_{\min}$ و ساعت‌های تغییر دوره تعرفه را پیش از مشاهده نتیجه تعریف و MAE، هزینه و نرخ نقض را جداگانه گزارش کند.

فصل ۵

نتیجه‌گیری و پیشنهادها

این پژوهش یک کنترل‌کننده یادگیری فیزیکی تعبیه‌شده برای ریزشبکه متصل به شبکه ارائه کرد. به‌جای پیش‌بینی مستقل توان شبکه، شارژ، دشارژ و SOC، شبکه تنها فرمان علامت‌دار باتری را پیش‌بینی می‌کند. یک لایه تحلیلی، توان شارژ و دشارژ، SOC گام بعد و توان شبکه را از این فرمان می‌سازد. در نتیجه توازن توان، حدود SOC، سقف توان باتری، نامنفی بودن توان‌ها و عدم شارژ/دشارژ هم‌زمان به‌صورت ساختاری برقرارند.

آزمایش روی ۳۲۸۹ ساعت داده عمومی ترکیبی و پنج بذر انجام شد. مدل داده‌محور خام MSE کمتری نسبت به برنامه مرجع داشت، اما در آزمون بازگشتی به‌ترتیب حدود ۷٫۱٪، ۳۰٫۳٪، ۳۱٫۷٪، ۴۰٫۹٪ شارژ/دشارژ هم‌زمان تولید کرد. مدل فیزیکی تعبیه‌شده همه این نرخ‌ها و باقیمانده توازن را، بر اساس مدل تعریف‌شده، به صفر رساند. هزینه اجرایی آن حدود ۲۱٫۴٪ کمتر از حالت بدون باتری و ۱۱٫۶٪ بیشتر از مرجع برنامه‌ریزی پویا بود. هزینه مدل فیزیکی تعبیه‌شده و مدل داده‌محور ترمیم‌شده قابل مقایسه بود؛ مقدار مدل نخست به‌طور میانگین اندکی کمتر بود، اما این تفاوت در پنج بذر معنادار نیست. بنابراین، نتیجه پروژه این نیست که شبکه عصبی از بهینه‌سازی دقیق بهتر است؛ نتیجه محدودتر و قابل دفاع‌تر آن است که پارامتردهی فیزیکی می‌تواند یک تقریب عصبی را به برنامه‌ای قابل اجرا تبدیل کند.

نتایج به همین مطالعه موردی عمومی/ترکیبی محدودند و صفر بودن نقض‌های تعریف‌شده خاصیت طراحی لایه است، نه کشف آماری. تبادل شبکه در مدل نامحدود است؛ در کاربردهایی که سقف تبادل دارند، می‌توان نداشت سخت را با گیره P_G و قاعده سازگار تخصیص توان گسترش داد. باتری نیز بدون دما و پیری مدل شده است و ورودی‌های پیش‌بینی و مرجع DP از آینده‌نگری کامل بهره می‌برند.

کارهای آینده باید این محدودیت‌ها را با پروتکل از پیش تعیین‌شده بیازمایند: جاروب جداگانه $P_{\max}$ ، $E_{\max}$ ، بازده‌ها، κ و فاصله تعرفه؛ حذف ورودی‌های $t + 1$ و $t + 3$ برای مطالعه حذفی؛ افزودن خطای پیش‌بینی؛ و آزمون روی روزهای خارج از توزیع. برای هر حالت باید مرجع و پنج بذر دوباره اجرا و هزینه، خطا و نقض‌ها بدون انتخاب پسینی گزارش شوند. استفاده از بار و PV هم‌مکان، مدل پیری و دما، سقف تبادل شبکه و مقایسه با MPC یا MILP نیز لازم است. اگر مسئله چنددزی نفعه واقعاً موضوع پژوهش بعدی باشد، تخصیص منفعت باید پس از تعیین برنامه توان و با داده و معیار انصاف روشن اضافه شود؛ در نسخه حاضر چنین ادعایی مطرح نیست.

فصل آ

مشخصات بازتولیدپذیری

این پیوست مقادیر به کاررفته در نسخه بایگانی شده آزمایش را یک جا گرد می آورد. با دریافت داده عمومی طبق `code/data/README.md`، اجرای `code/prepare_public_data.py` و سپس `code/simulate.py`، خواننده می تواند برنامه مرجع، آموزش پنج بذر، جداول شاخص ها و شکل ها را بازتولید کند. نسخه ی پایدار کد و داده در نشانی <https://github.com/generalmab3/Bonab-Latex> در دسترس است و دستورات بازتولید در همین پیوست آمده اند.

جدول ۱-آ. پارامترهای کامل شبیه سازی و آموزش

پارامتر	مقدار	منبع در کد/داده
η_c, η_d	۰٫۹۵, ۰٫۹۵	simulate.py
$E_{\max}$	۲٫۰ kWh	simulate.py
$P_{\max}$	۱٫۰ kW	simulate.py
$s_{\min}, s_{\max}$	۰٫۲۰, ۰٫۹۰	simulate.py
κ	۰٫۰۰۸ واحد پولی بر کیلووات ساعت عبوری	simulate.py
Δt	۱ h	simulate.py
تعرفه خرید c_b	کم باری ۰٫۱۶؛ عادی ۰٫۲۲؛ اوج ۰٫۳۴؛ تخفیف ۰٫۰۲	metadata.json: دوره های دقیق ساعت به ساعت در public_microgrid_case.csv
تعرفه فروش c_s	آخر هفته ۰٫۰۲	metadata.json
شبکه SOC در DP	۰٫۲۰ تا ۰٫۹۰ با گام ۰٫۰۱ (۷۱ نقطه)	SOC_GRID
شبکه فرمان در DP	۴۱ مقدار یکنواخت روی $[-1, 1]$ kW	ACTION_GRID
شرط نهایی DP	$V_T(s) = 0$	dynamic_programming_reference
معماری هر شبکه	دو لایه پنهان ۳۲ واحدی با $\tanh$	MLP کلاس
اندازه دسته	۶۴	BATCH
بیشینه دوره آموزش	۴۵۰	EPOCHS

پارامتر	مقدار	منبع در کد/داده
شکیبایی توقف زودهنگام	۵۵ دوره	PATIENCE
بهینه‌ساز و نرخ یادگیری	آدام؛ $10^{-3} \times 1,2$	LR و MLP.adam
بذرها	۷, ۱۱, ۱۹, ۲۳, ۲۹	SEEDS
افراز داده	زمانی ۲۰/۲۰/۶۰	simulate.py
	۶۵۹/۶۵۷/۱۹۷۳	

در جدول تعرفه، قیمت‌ها از متادیتای موجود استخراج شده‌اند؛ برای جلوگیری از تکرار یا خطای انتقال، تعریف دقیق دوره‌های زمانی همان سری ساعت‌به‌ساعت نسخه‌بندی شده در فایل CSV است. فرمان‌های بازتولید عبارت‌اند از:

```
python3 -m venv .venv
.venv/bin/pip install -r code/requirements.txt
.venv/bin/python code/test_physics.py
.venv/bin/python code/simulate.py
.venv/bin/python code/benchmark_runtime.py
```

فصل ب

شبه‌کد لایه خروجی تحلیلی

الگوریتم زیر همان ترتیب محاسبات روابط (۳-۳) تا (۳-۶) را بدون وابستگی به زبان برنامه‌نویسی نشان می‌دهد. عملگر $\min$ در سقف‌ها و تفکیک علامت فرمان، امکان‌پذیری محلی باتری را پیش از محاسبه توان شبکه اعمال می‌کند.

```
INPUT: current SOC s, unconstrained network output z,
       load P_L, PV power P_PV, and model parameters

u <- P_max * tanh(z)
charge_cap <- min(P_max, (s_max - s) * E_max / (eta_c * Delta_t))
discharge_cap <- min(P_max, (s - s_min) * E_max * eta_d / Delta_t)

P_c <- min(max(u, 0), charge_cap)
P_d <- min(max(-u, 0), discharge_cap)

s_next <- s
          + eta_c * P_c * Delta_t / E_max
          - P_d * Delta_t / (eta_d * E_max)
P_G <- P_L + P_c - P_PV - P_d

RETURN P_c, P_d, s_next, P_G
```

1-ب. کد Analytical hard-constraint output layer

منابع

- [1] I. O. Oladejo and K. A. Folly, “Management of grid-connected micro-grid using game theory approach,” in *2019 Southern African Universities Power Engineering Conference/Robotics and Mechatronics/Pattern Recognition Association of South Africa (SAUPEC/RobMech/PRASA)*, Bloemfontein, South Africa, 2019, pp. 1–6.
- [2] M. El-Hendawi, H. A. Gabbar, G. El-Saady, and E.-N. A. Ibrahim, “Optimal operation and battery management in a grid-connected microgrid,” *Journal of International Council on Electrical Engineering*, vol. 8, no. 1, pp. 195–206, 2018. DOI: 10.1080/22348972.2018.1528662
- [3] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019. DOI: 10.1016/j.jcp.2018.10.045
- [4] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang, “Physics-informed machine learning,” *Nature Reviews Physics*, vol. 3, no. 6, pp. 422–440, 2021. DOI: 10.1038/s42254-021-00314-5
- [5] L. M. Candanedo, V. Feldheim, and D. Deramaix, “Data driven prediction models of energy use of appliances in a low-energy house,” *Energy and Buildings*, vol. 140, pp. 81–97, 2017. DOI: 10.1016/j.enbuild.2017.01.083
- [6] L. M. Candanedo, *Appliances energy prediction*, UCI Machine Learning Repository, 2017. DOI: 10.24432/C5VC8G [Online]. Available: <https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction>
- [7] NASA Prediction Of Worldwide Energy Resources, *Power daily api: All sky surface shortwave downward irradiance*, Subset and exact request URL are

- versioned with the project data, 2016. Accessed: Aug. 24, 2026. [Online]. Available: <https://power.larc.nasa.gov/>
- [8] L. Lu, R. Pestourie, W. Yao, Z. Wang, F. Verdugo, and S. G. Johnson, “Physics-informed neural networks with hard constraints for inverse design,” *SIAM Journal on Scientific Computing*, vol. 43, no. 6, B1105–B1132, 2021. DOI: 10.1137/21M1397908
 - [9] H. Chen, G. E. C. Flores, and C. Li, “Physics-informed neural networks with hard linear equality constraints,” *Computers & Chemical Engineering*, vol. 189, p. 108 764, 2024. DOI: 10.1016/j.compchemeng.2024.108764
 - [10] D. P. Bertsekas, *Dynamic Programming and Optimal Control, Volume I*, 4th ed. Belmont, MA: Athena Scientific, 2017.
 - [11] A. Parisio, E. Rikos, and L. Glielmo, “A model predictive control approach to microgrid operation optimization,” *IEEE Transactions on Control Systems Technology*, vol. 22, no. 5, pp. 1813–1827, 2014. DOI: 10.1109/TCST.2013.2295737
 - [12] A. Parisio, E. Rikos, G. Tzamalīs, and L. Glielmo, “Use of model predictive control for experimental microgrid optimization,” *Applied Energy*, vol. 115, pp. 37–46, 2014. DOI: 10.1016/j.apenergy.2013.10.027
 - [13] A. Vázquez-Canteli and Z. Nagy, “Reinforcement learning for demand response: A review of algorithms and modeling techniques,” *Applied Energy*, vol. 235, pp. 1072–1089, 2019. DOI: 10.1016/j.apenergy.2018.11.002
 - [14] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *3rd International Conference on Learning Representations*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
 - [15] E. Altman, *Constrained Markov Decision Processes*. Chapman and Hall/CRC, 1999. DOI: 10.1201/9781315140223
 - [16] J. Achiam, D. Held, A. Tamar, and P. Abbeel, “Constrained policy optimization,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 22–31. [Online]. Available: <https://proceedings.mlr.press/v70/achiam17a.html>

- [17] Y. Chow, O. Nachum, E. Duenez-Guzman, and M. Ghavamzadeh, “A lyapunov-based approach to safe reinforcement learning,” in *Advances in Neural Information Processing Systems*, vol. 31, 2018. [Online]. Available: <https://proceedings.neurips.cc/paper/2018/hash/4fe5149039b52765bde64beb9f674940-Abstract.html>
- [18] A. Ray, J. Achiam, and D. Amodei, *Benchmarking safe exploration in deep reinforcement learning*, OpenAI technical report, 2019. [Online]. Available: <https://cdn.openai.com/safexp-short.pdf>
- [19] J. García and F. Fernández, “A comprehensive survey on safe reinforcement learning,” *Journal of Machine Learning Research*, vol. 16, pp. 1437–1480, 2015. [Online]. Available: <https://jmlr.org/papers/v16/garcia15a.html>
- [20] B. Amos and J. Z. Kolter, “Optnet: Differentiable optimization as a layer in neural networks,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 136–145. [Online]. Available: <https://proceedings.mlr.press/v70/amos17a.html>
- [21] B. Amos, L. Xu, and J. Z. Kolter, “Input convex neural networks,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 146–155. [Online]. Available: <https://proceedings.mlr.press/v70/amos17b.html>

Abstract

Energy management of a grid-connected microgrid must account for operating cost as well as battery constraints. A neural network that independently predicts grid exchange, charge, discharge and state of charge can achieve a small approximation error while producing an infeasible command, such as simultaneous charging and discharging or an out-of-range state of charge. This study develops a physics-embedded neural network that learns only a signed battery command. A parameter-free analytical output layer derives charge, discharge, next state of charge and grid power so that power balance, state-of-charge bounds, battery power limits, non-negativity and charge-discharge exclusivity hold by construction.

The case study contains 3,289 hourly records over the processed interval from 17:00 on 11 January to 17:00 on 27 May 2016, assembled transparently from public data: appliance-and-light demand is taken from a public data set and solar irradiation from NASA POWER, while the PV model, background load and tariff are stated engineering assumptions. A constrained dynamic-programming schedule provides a reference. An unconstrained data-driven MLP and the physics-embedded MLP are trained with a chronological 60/20/20 split and five random seeds, then evaluated in autoregressive test rollouts.

The physics-embedded model reduced the power-balance residual and every defined constraint-violation rate to zero in floating-point evaluation. Although the raw data-driven model had a lower MSE, it produced about 7.1 percent state-of-charge violations and 40.9 percent simultaneous charge-discharge commands. The physics-embedded controller cost 17.186 ± 0.242 , i.e., 21.4 percent less than grid-only operation and 11.6 percent more than the dynamic-programming reference. Its cost was comparable to, and slightly lower on average than, the repaired data-driven model (17.529 ± 0.492), but the difference was not significant across five seeds. Zero violations are a design property, not a statistical discovery. The finding is limited to this hybrid public-data case study and is not claimed to generalize to field or industrial operation.

Keywords: Physics-informed learning, hard constraints, grid-connected micro-

grid, energy management, battery



University of Bonab

Faculty of Basic Sciences

Department of Mathematics and Computer Science

A B.Sc. Project in Computer Science

Hard-Constraint Physics-Informed Learning for Energy Management of a Grid-Connected Microgrid

Supervisors

Dr. Babak Azarnavid

Dr. Zahra Mokhtarnejad

By

Muhammad Amir Babazad

Student ID: 1402135104

September 2026